

# NUMERICAL COMPUTATION METHODS

## HOMEWORK 1

学院: 数据科学与计算机学院

班级: 软工 3 班

姓名: 李天译

学号: 16340122

## Contents

<b>1</b>	<b>直接法</b>	<b>2</b>
1.1	问题描述 . . . . .	2
1.2	Gauss 消去法 . . . . .	2
1.2.1	算法设计 . . . . .	2
1.2.2	数值实验 . . . . .	3
1.3	列主元消去法 . . . . .	4
1.3.1	算法设计 . . . . .	4
1.4	结果分析 . . . . .	4
<b>2</b>	<b>迭代法</b>	<b>6</b>
2.1	问题描述 . . . . .	6
2.2	Jacobi . . . . .	6
2.2.1	算法设计 . . . . .	6
2.2.2	数值实验 . . . . .	7
2.3	Gauss-Seidel . . . . .	8
2.3.1	算法设计 . . . . .	8
2.3.2	数值实验 . . . . .	8
2.4	SOR . . . . .	9
2.4.1	算法设计 . . . . .	9
2.4.2	数值实验 . . . . .	10
2.5	CG . . . . .	12
2.5.1	算法设计 . . . . .	12

2.5.2 数值实验 . . . . .	13
2.6 结果分析 . . . . .	14
<b>3 Page Rank</b>	<b>15</b>
3.1 问题描述 . . . . .	15
3.2 算法设计 . . . . .	15
3.3 结果分析 . . . . .	17

# 1 直接法

## 1.1 问题描述

实现高斯消去法和列主元消去法, 求解线性方程组  $Ax = b$ , 其中  $A$  为  $n \times n$  维的已知矩阵,  $b$  为  $n$  维的已知向量,  $x$  为  $n$  维的未知向量.  $A$  与  $b$  中的元素服从独立同分布的正态分布. 令  $n = 10\ 50\ 100\ 200$ , 测试计算时间并绘制曲线.

## 1.2 Gauss 消去法

### 1.2.1 算法设计

根据高斯消去法的原理, 算法主要分为两步:

- 消元:

$$m_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$$

$$k = 1, 2, \dots, n-1; i = k+1, k+2, \dots, n$$

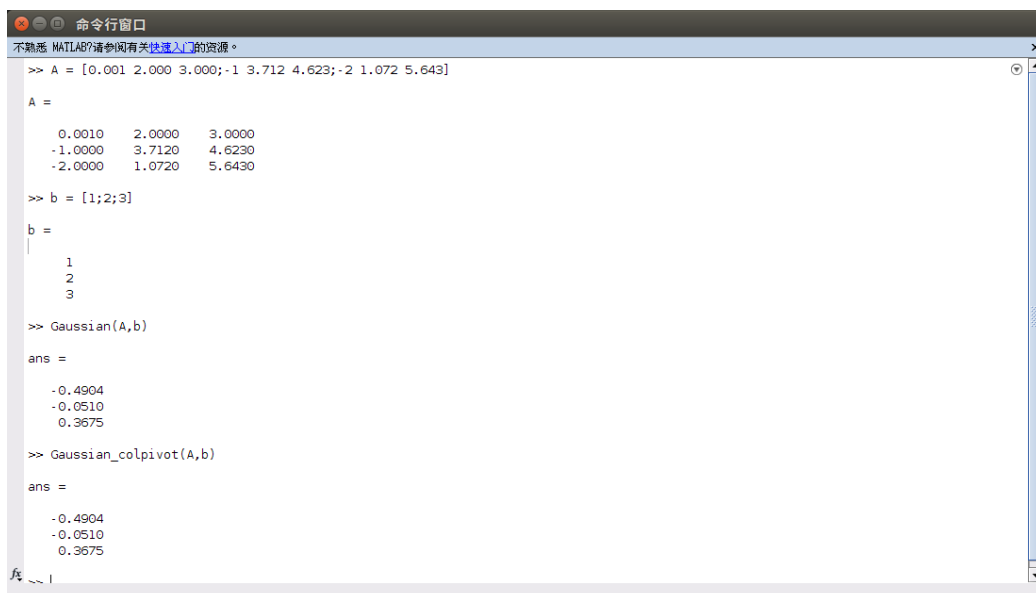
再将  $-m_{ik}$  乘以原式的第  $k$  行，加到第  $i$  行上.

- 回代:

$$\begin{aligned}x_n &= b_n^{(n)} / a_{nn}^{(n)} \\x_k &= \frac{b_k^{(n)} - \sum_{j=k+1}^n a_{kj}^{(n)} x_j}{a_{kk}^{(k)}} \\k &= n-1, n-2, \dots, 1\end{aligned}$$

### 1.2.2 数值实验

理论上高斯消去法的数值稳定性较差，但使用教材 5.2.3 的例子实验时并没有发现与列主元消去法的计算结果有明显差别. 结果如下:



```
>> A = [0.001 2.000 3.000;-1 3.712 4.623;-2 1.072 5.643]

A =

    0.0010    2.0000    3.0000
   -1.0000    3.7120    4.6230
   -2.0000    1.0720    5.6430

>> b = [1;2;3]

b =

     1
     2
     3

>> Gaussian(A,b)

ans =

   -0.4904
   -0.0510
    0.3675

>> Gaussian_colpivot(A,b)

ans =

   -0.4904
   -0.0510
    0.3675
```

## 1.3 列主元消去法

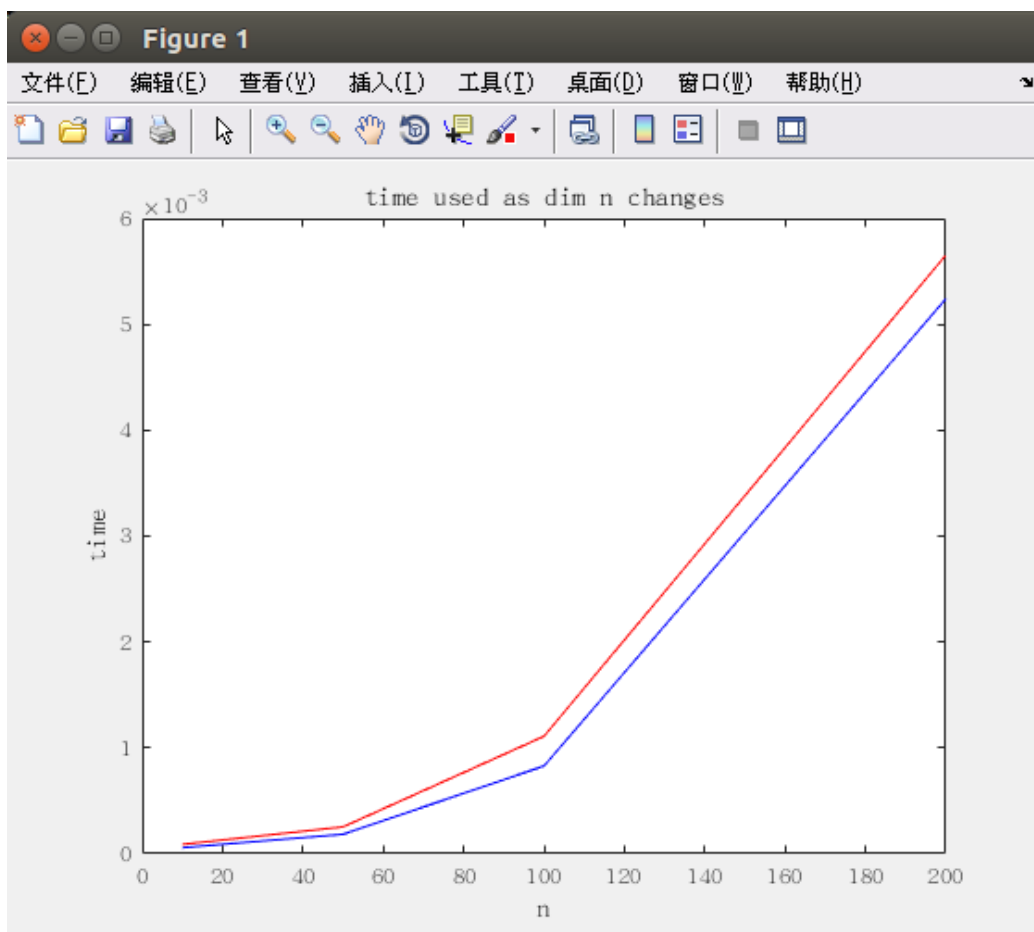
### 1.3.1 算法设计

在高斯消去法的基础上，为了解决高斯消去法可能出现的数值不稳定的情况，每次迭代取剩余行中绝对值最大的行作为该次迭代的列主元，其余操作与高斯消去法相同。

### 1.4 结果分析

使用维数  $n$  作为横坐标，计算时间作为纵坐标，画出了时间变化曲线。由于使用的是随机出的矩阵  $A$  和向量  $b$ ，每次得到的图像都有一些区别，但大体趋势都相同，且能看出列主元消去法在多数情况下要比高斯消去法耗时更长（尤其当  $n$  增大时），猜测这样的结果是列主元法比高斯消去法多比

较，甚至可能交换了行元素，增加了时间复杂度导致的，但时间复杂度的少许增加提高了算法的数值稳定性. 曲线的变化基本符合理论上高斯消去法的时间复杂度:  $O(\frac{1}{3}n^3)$ . 某次的实验结果如下图: (红色线为列主元消去法, 蓝色线为高斯消去法)



## 2 迭代法

### 2.1 问题描述

实现 Jacobi 迭代法, Gauss-Seidel 迭代法, 逐次超松弛迭代法和共轭梯度法, 求解线性方程组  $Ax = b$ , 其中  $A$  为  $n \times n$  维的已知矩阵,  $b$  为  $n$  维的已知向量,  $x$  为  $n$  维的未知向量.  $A$  与  $b$  中的元素服从独立同分布的正态分布. 令  $n = 10\ 50\ 100\ 200$ , 分别绘制出算法的收敛曲线, 横坐标为迭代步数, 纵坐标为相对误差. 比较 Jacobi 迭代法, Gauss-Seidel 迭代法, 逐次超松弛迭代法, 共轭梯度法与高斯消去法, 列主元消去法的计算时间. 改变逐次超松弛迭代法的松弛因子  $\omega$ , 分析其对收敛速度的影响.

### 2.2 Jacobi

#### 2.2.1 算法设计

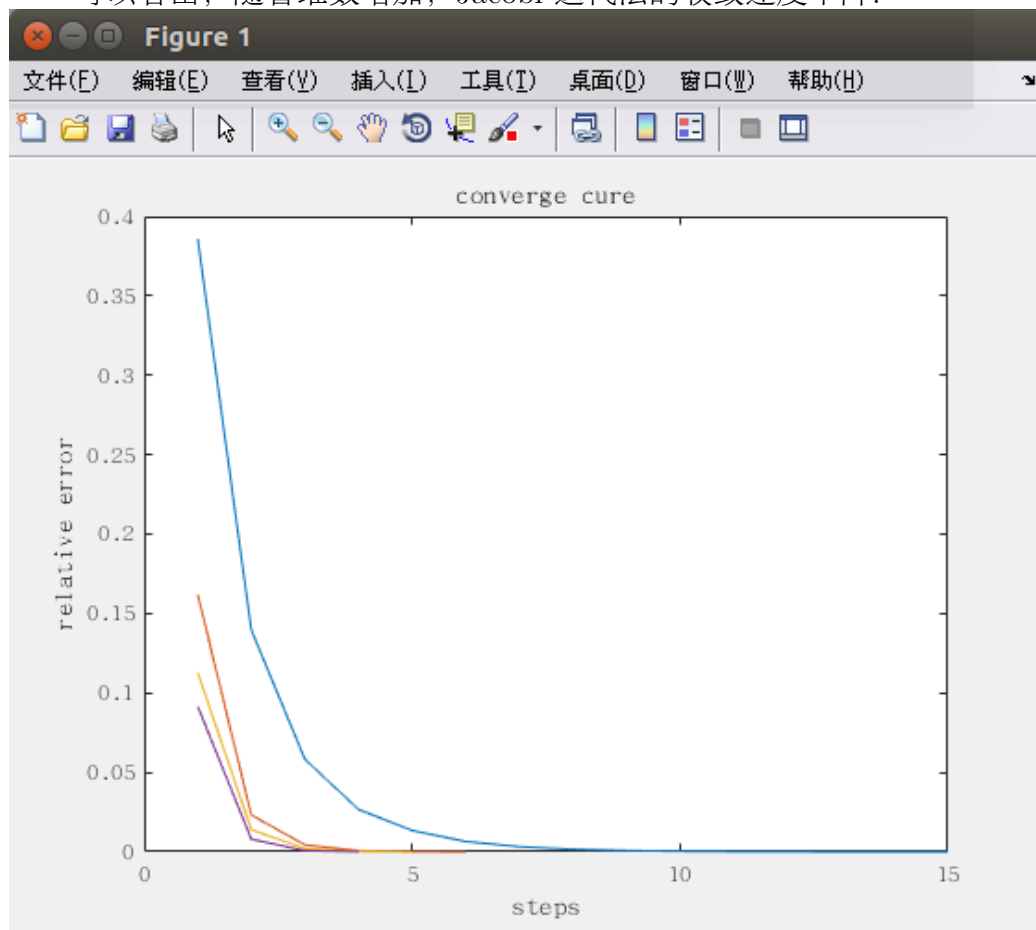
根据公式有:

$$\begin{aligned}x^{(0)} &= (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T \\x_i^{(k+1)} &= \frac{b_i - \sum_{j=1, j \neq i}^n a_{ij} x_j^{(k)}}{a_{ii}} \\i &= 1, 2, \dots, n; k = 0, 1, \dots\end{aligned}$$

直到误差很小时停止.

### 2.2.2 数值实验

可以看出，随着维数增加，Jacobi 迭代法的收敛速度下降。





## 2.3 Gauss-Seidel

### 2.3.1 算法设计

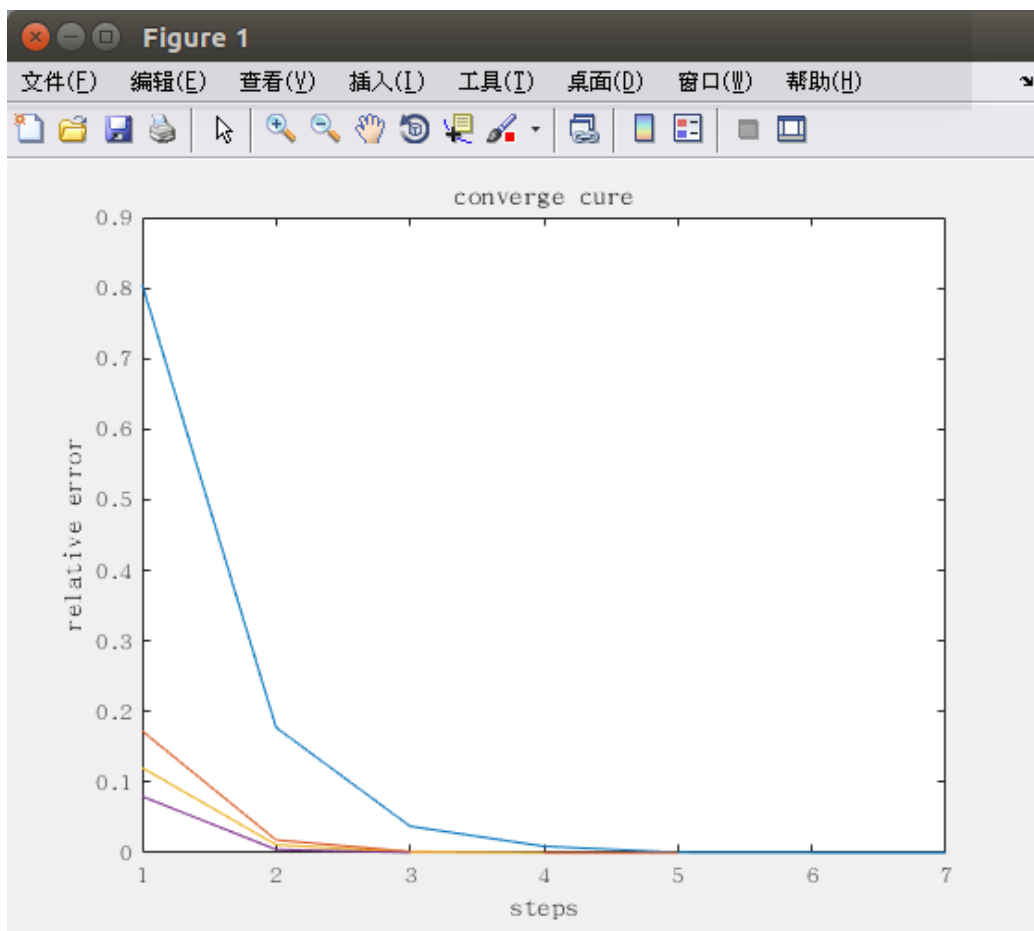
与 Jacobi 法类似，但在每一步迭代中用到当前已更新值的信息加速收敛. 根据公式有:

$$\begin{aligned}x^{(0)} &= (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T \\x_i^{(k+1)} &= x_i^{(k)} + \Delta x_i \\ \Delta x_i &= \frac{b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i}^n a_{ij}x_j^{(k)}}{a_{ii}} \\ i &= 1, 2, \dots, n; k = 0, 1, \dots\end{aligned}$$

直到误差很小时停止.

### 2.3.2 数值实验

可以看出，随着维数增加，Gauss-Seidel 迭代法的收敛速度下降，并且对比发现，本方法误差随步长的变化较 Jacobi 迭代法更大.



## 2.4 SOR

### 2.4.1 算法设计

以  $\omega$  作为松弛因子，在 Gauss-Seidel 方法上加以变化，得到逐次超松弛迭代法公式。

$$x^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T$$

$$x_i^{(k+1)} = x_i^{(k)} + \Delta x_i$$

$$\Delta x_i = \frac{\omega(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i}^n a_{ij}x_j^{(k)})}{a_{ii}}$$

$$i = 1, 2, \dots, n; k = 0, 1, \dots$$

直到误差很小时停止.

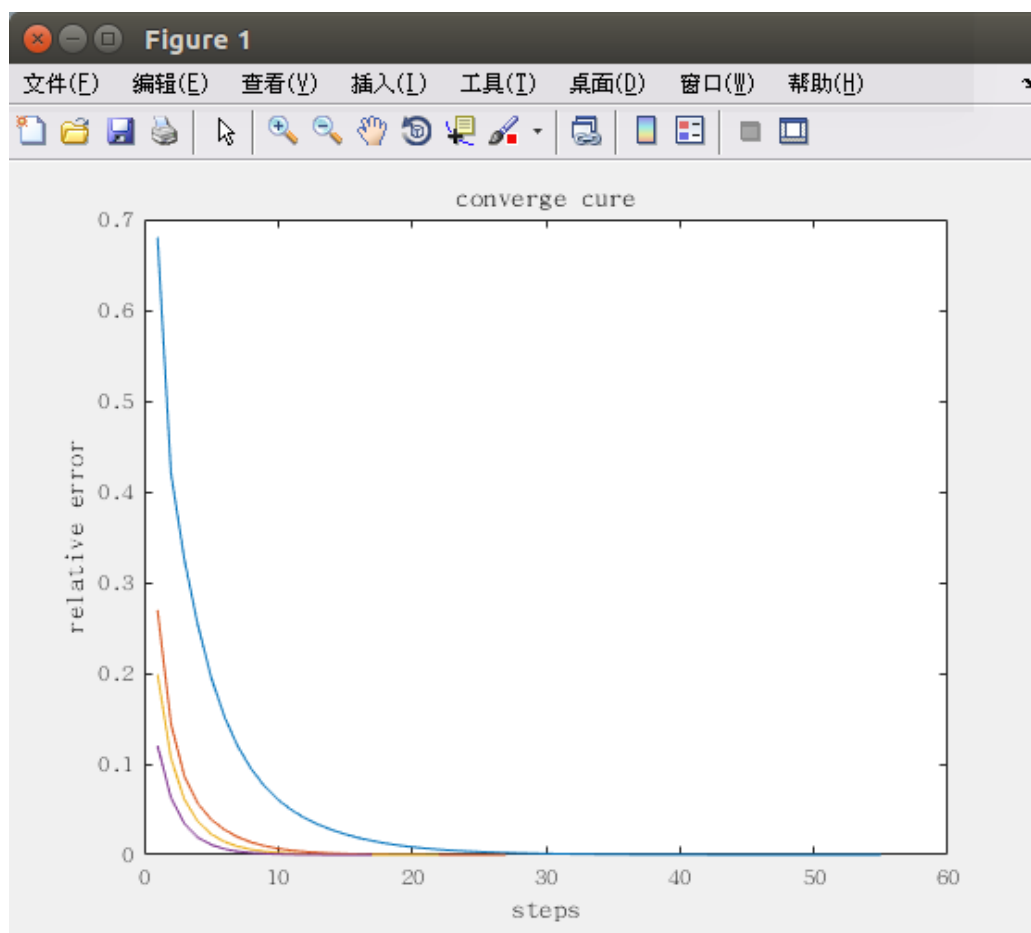
可以看出, 高斯-塞德尔迭代实质上就是  $\omega = 1$  时的逐次超松弛迭代法(SOR)

.

#### 2.4.2 数值实验

- 收敛随维数变化:

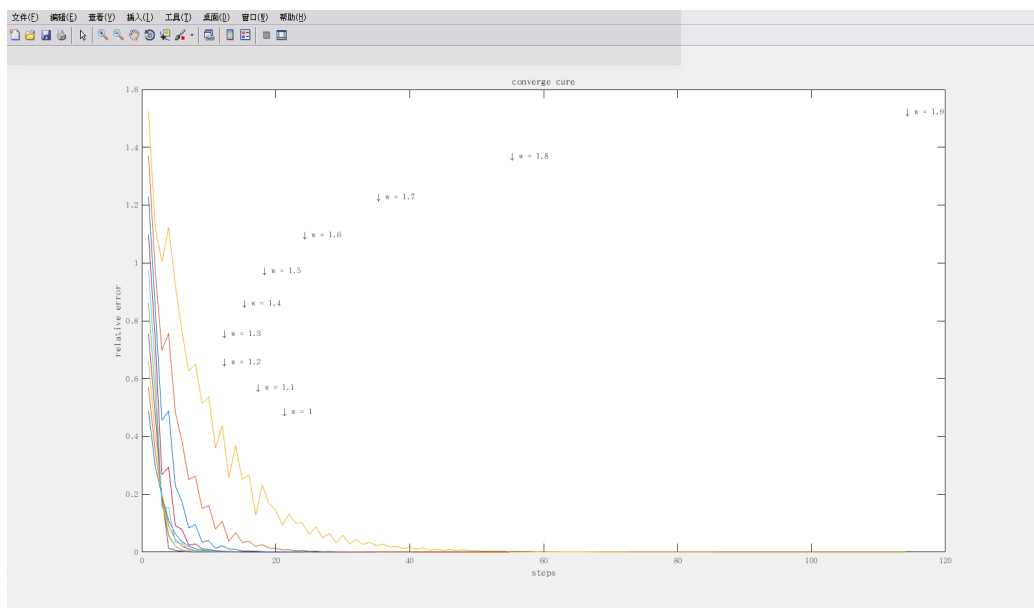
测试中取  $\omega = 1.5$ , 测试的迭代速度较慢.



- 松弛因子影响迭代步长:

使用教材中  $A, b$  的值为例, 以 0.1 为迭代步长, 在 (1, 2) 范围内 (超松弛的参数范围) 改变参数  $\omega$  的值, 测试收敛所需步数, 并标注在横坐标的对应位置.

可以看出  $\omega = 1.3$  是求解这个方程的近似最优松弛因子, 且收敛所需步数随松弛因子的值增加而先减少再增加.



## 2.5 CG

### 2.5.1 算法设计

根据公式可得:

取  $x^{(0)} = 0$ ,  $r^{(0)} = b - Ax^{(0)}$ , 取  $p^{(0)} = r^{(0)}$

对  $k = 0, 1, \dots$ , 计算:

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(p^{(k)}, Ap^{(k)})}$$

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$$

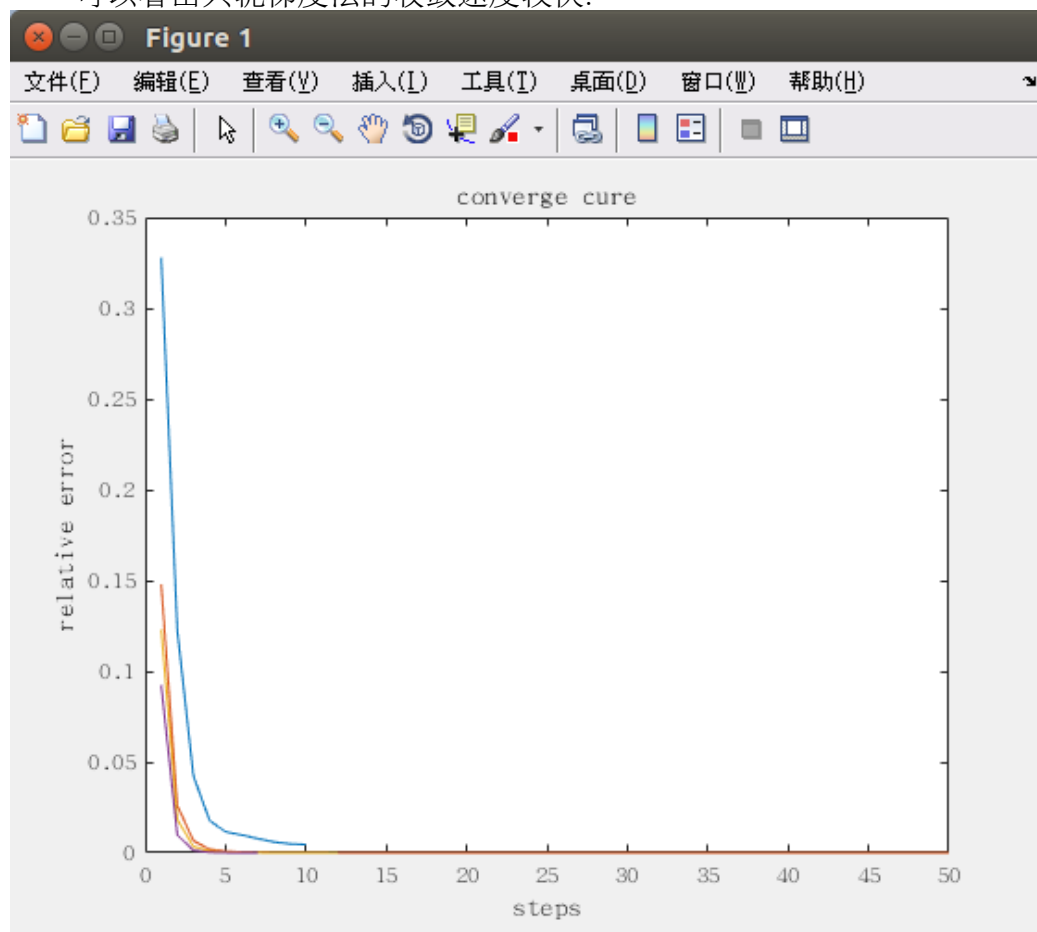
$$r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)}, \beta_k = \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})}$$

$$p^{(k+1)} = r^{(k+1)} + \beta_k p^{(k)}$$

直到误差很小时停止.


### 2.5.2 数值实验

可以看出共轭梯度法的收敛速度较快.



## 2.6 结果分析

比较上面提到的六种求线性方程解的方法，在维数改变时的计算时间，实验结果如下：



几点结论：

- 高斯消去法和列主元消去法的计算时间差别不大，Jacobi 和 Gauss-Seidel 迭代法的计算时间差别不大.
- 随着维数增加，直接法的两种方法计算时间变得显著高于迭代法的几种方法，且能看出直接法的两种方法受到维数影响变化更大.
- CG 法的计算时间受维数影响不大，且在维数增加时显著优于其他算法.
- 实验中选定的松弛因子  $\omega = 1.3$  下，SOR 比其他迭代法的方法计算时间更长，该因子的选取未能体现出 SOR 方法的优势.

### 3 Page Rank

#### 3.1 问题描述

在Epinions 社交数据集中, 每个网络节点可以选择信任其它节点. 借鉴Pagerank 的思想编写程序, 对网络节点的受信任程度进行评分. 在实验报告中, 请给出伪代码.

#### 3.2 算法设计

$$v^{(k+1)} = (1 - \beta)Av^{(k)} + \beta\frac{1}{n}I$$

$k = 1, 2, \dots$ , 当误差足够小时为止.

*% Pseudocode :*

edge E(x,y)

nodes N

matrix A

min\_error **error**

factor **beta** = 0.05

n x 1 matrix, **all** the elements are 1 I

**for** every edge E(x,y)

    A(x,y) = 1;

**end**




```
for every column c
     $A(:,c) = A(:,c) / (\text{sum of } c);$ 
end

while error of this step > error
    newv = (1-beta) * A * v + beta * 1/N * I;
    v = newv;
end
```

### 3.3 结果分析

前 500 个节点的排序结果如下:



但测试发现, 这些节点的 pr 值之和并不为 1, 猜测是由于多次迭代的舍入误差导致的.